Massimizzazione dell'influenza con vincolo di diversità su rete multistrato

Dal cancello sul substrato alla previsione di chi adotterà

Davide Cinelli Giuseppe Cuiuri

Analisi di Social Network e Media
CdLM in Ingegneria Informatica · DIMES, Università della Calabria

Docente: prof. Andrea Tagarelli

Settembre 2026

Due domande

LA DOMANDA DI PREVISIONE

Chi adotterà?

LA DOMANDA DI OTTIMIZZAZIONE

Da chi conviene partire?

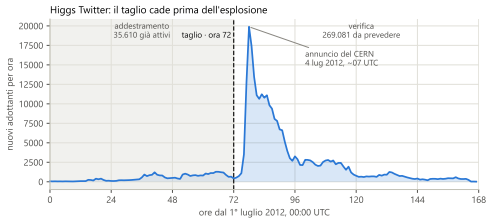
Il progetto è nato dalla seconda.
Misurando, la domanda centrale è diventata la prima.

La difficoltà non sono gli algoritmi

Nella quasi totalità dei lavori di IM le probabilità sono assegnate e i seed valutati sotto lo stesso modello che li ha scelti. Il ciclo si autoconferma.

Due dataset, due situazioni opposte

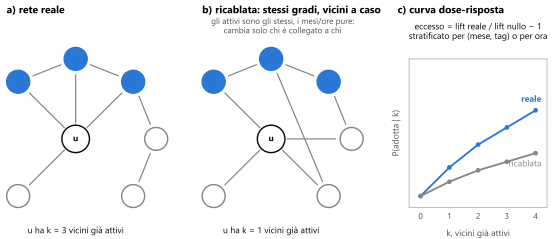
	StackExchange	Higgs Twitter
canale	risposte, commenti	grafo dei follower
nodi	46.312	456.627
archi	230.641	14.855.842
livelli	2	4
oggetto	105 tag, 12 anni	un evento, 7 giorni
confine	gennaio 2020	ora 72
da prevedere	64.711 esposizioni	269.081 adottanti
eccesso strutturale	-0%	$+73\%$



Il taglio cade *poche ore prima* dell'annuncio del CERN: i seed si scelgono quando l'evento non è ancora esploso.

Il cancello: la rete conta, qui?

Una misura decisa prima di costruire qualunque cosa



Se i tuoi vicini hanno adottato, tu adotti di più. Ma chi ha molti vicini è più attivo.

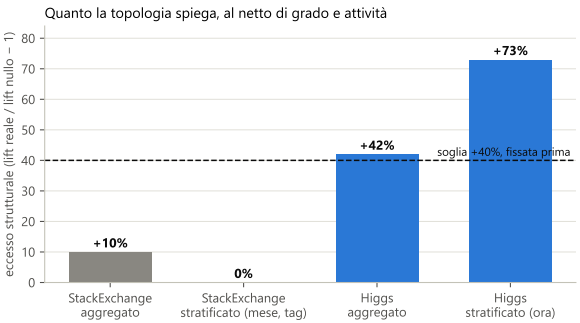
Si confronta la rete reale con reti **ricablate a gradi preservati**: stessi nodi, stesso numero di vicini, vicini diversi.

$$\text{eccesso} = \frac{\text{lift reale}}{\text{lift nullo}} - 1$$

Stratificato per (mese, tag) o per ora: nei momenti di picco tutti sono esposti e tutti adottano, e il rapporto aggregato lo scambia per rete.

Soglia +40%, fissata prima di misurare.

Il cancello: il verdetto in entrambe le direzioni



StackExchange: il +10% aggregato sparisce stratificando — 1,54× reale contro 1,54× nullo. Era composizione del campione.

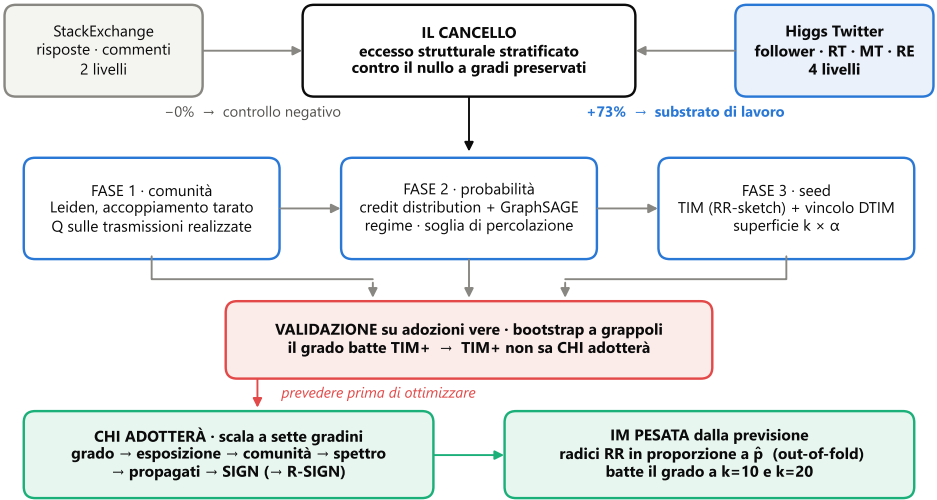
Higgs: +42% aggregato, +73% stratificato.

Che cosa spiega

Ogni risultato nullo della prima versione — GNN, diversità, competitivo — non era un difetto di implementazione: non c'era struttura da trovare.

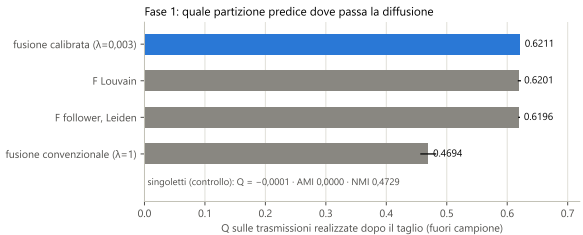
StackExchange resta come **controllo negativo**.

L'architettura



Fase 1 — le comunità predicono dove passa la diffusione

Criterio fuori campione: modularità sulle trasmissioni realizzate *dopo* il taglio



$$Q_{\text{tras}} = 0{,}62$$

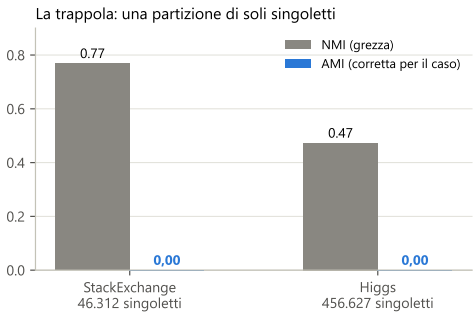
contro 0,13 su StackExchange; il 74% delle 5,6 M trasmissioni resta dentro la comunità, 7× il caso.

Leiden ≡ Louvain ($p = 0{,}19$).

Il multistrato paga solo tarato: con la normalizzazione convenzionale la fusione crolla a 0,47; con il peso degli strati scelto in campione ($\lambda = 0{,}003$) vince, $p < 0{,}001$.

Il verdetto sul multistrato dipende da una scelta che di solito non viene dichiarata.

Fase 1 — la trappola della metrica



Una partizione di **soli singoletti** — ogni nodo da solo, nessuna struttura —

	StackExchange	Higgs
NMI (grezza)	0,77	0,47
AMI (corretta per il caso)	0,00	0,00
Q (nullo dentro)	−0,004	−0,0001

L'NMI non sottrae l'accordo casuale e premia la granularità come se fosse accuratezza. Riprodotto su due substrati.

Ogni metrica del lavoro ha il modello nullo dentro.

Fase 2 — probabilità stimate, non assegnate

Credit distribution, orientata, sui retweet *osservati*:

$$p(u \to v) = \frac{\text{trasmissioni}(u \to v)}{\text{attività}(u) + s}$$

28.498 archi con dati su 14,8 M — lo 0,19%.

GraphSAGE estende la stima agli altri:

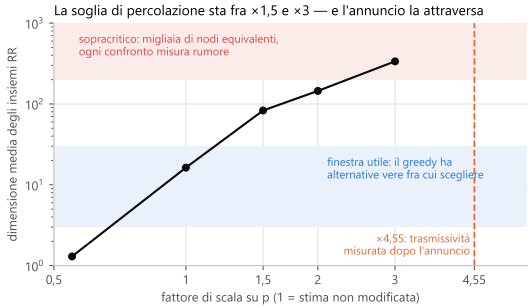
modello di p	MSE	vs costante
loss uniforme	0,000222	−86%
loss pesata sugli hub	0,000261	−2,1% sugli hub
costante	0,001588	—

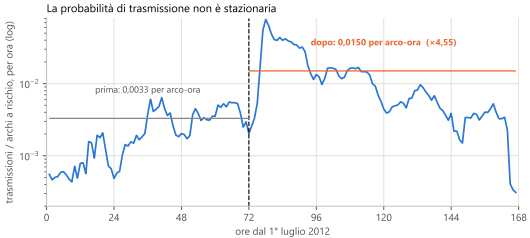
La loss pesata è respinta **su entrambi i substrati** ($-2{,}1\%$ e $-2{,}0\%$): una replica, non un secondo tentativo.

Due scelte

- un solo verso per arco: il verso opposto non è «influenza zero», è assenza di canale
- quattro archi *negativi* per ogni ricco, o la rete sovrastima sui poveri

Fase 2 — la soglia di percolazione, e l'annuncio che la attraversa

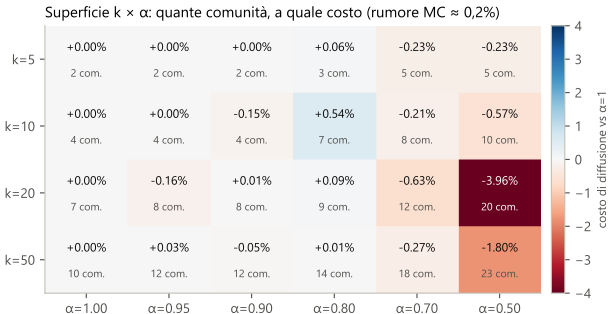




Alla scala 1 — la stima non modificata — il sistema è sottocritico: **nessuna riscalatura** (su StackExchange serviva 0,25). La soglia sta fra $\times 1{,}5$ e $\times 3$. Dopo l'annuncio la trasmissività per arco-ora sale di **4,55**$\times$: **nel periodo calmo la rete non percola, l'annuncio la spinge sopra soglia.** L'esplosione non è arrivata dalla rete; la rete l'ha amplificata.

Fase 3 — quanto costa la diversità

$s(v) = \alpha \cdot |R_v| / \max_u |R_u| + (1 - \alpha) \cdot \mathbf{1}[c(v) \notin C]$



Rumore Monte Carlo sulla differenza fra due celle: $\approx 0{,}2\%$.

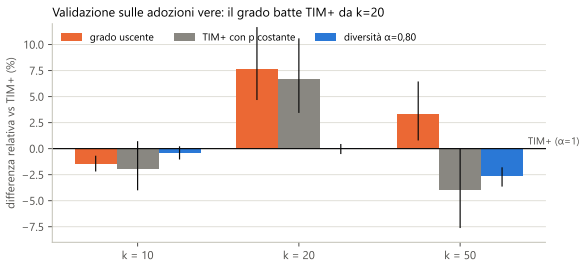
A $k = 50$: da 10 a **14 comunità gratis**, a 18 per lo 0,27%, tutte e 23 per l'1,8%.

A $k = 10$: da 4 a 7 comunità $+0{,}54\%$ — spargere i seed riduce la sovrapposizione.

Su StackExchange la stessa mossa a $k = 5$ costava l'1,35% e apriva comunità da due nodi. Qui il vincolo ha 23 comunità bilanciate su cui lavorare.

La validazione

Punteggio $= \sum_v \pi(v)$ sui 269.081 veri adottanti; bootstrap a grappoli sull'ora



Il grado batte TIM+

$+7{,}66\%$ a $k = 20$, $+3{,}34\%$ a $k = 50$, $p \leq 0{,}001$. Regge anche a $\times 4{,}55$.

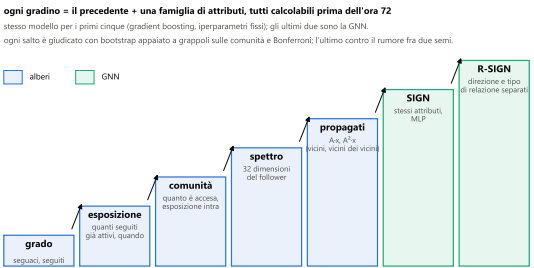
Credit distribution, GraphSAGE, RR-sketch e greedy con garanzia $1 - 1/e$ perdono contro «prendi i venti account con più follower».

Non è rumore: il modello batte il caso del 24–98%. È che **TIM+ massimizza *quanti*, e non sa *quali***.

Il vincolo di diversità è gratis: $-0{,}02\%$ a $k = 20$, $p = 0{,}93$.

Chi adotterà — la scala a pioli

Sui 421.017 non attivi all'ora 72: chi adotta nelle 96 ore dopo?

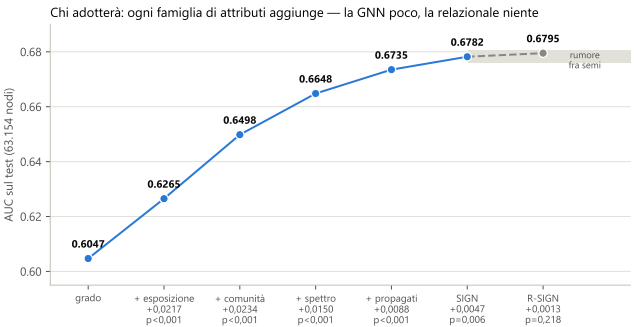


Ogni gradino = il precedente + una famiglia di attributi, tutti pre-taglio. Stesso modello per i primi cinque; gli ultimi due sono la GNN.

Le comunità entrano come **numeri** — quanto è accesa la mia, quanta esposizione viene da dentro — non come identità.

Ogni salto: bootstrap a grappoli **sulle comunità**, Bonferroni, e il rumore fra due semi come metro dell'ultimo.

Chi adotterà — cinque salti, cinque positivi



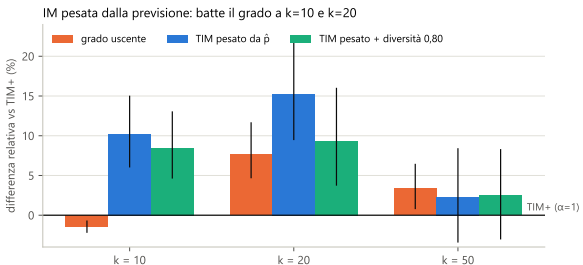
salto	ΔAUC
grado → esposizione	+0,022
→ **comunità**	**+0,023**
→ spettro	+0,015
→ propagati	+0,009
→ SIGN	+0,005
→ R-SIGN	+0,001, n.s.

Tutti i primi cinque sotto Bonferroni. **Le comunità sono il gradino più grande.** La GNN aggiunge poco ma davvero; la struttura relazionale informa gli alberi, non la GNN.

AUC finale 0,68: modesta, e va detto.

IM pesata dalla previsione

Radici degli insiemi RR in proporzione a $\hat{p}(v)$, prodotta *out-of-fold*



Contro il grado, direttamente:

k	TIM pesato	p
10	$+\mathbf{11{,}85\%}$	$< 0{,}001$
20	$+\mathbf{7{,}06\%}$	$< 0{,}001$
50	$-1{,}01\%$	$0{,}73$

Sceglie **pochi seed già attivi**: 7 su 20, contro 20 su 20 di TIM+. Trova chi non parla ancora dell'evento ma raggiunge chi adotterà.

Un'AUC di 0,68 basta: il peso non deve essere buono, deve essere *meglio dell'uniforme*.

Che cosa non ha funzionato

componente	esito, e come è stato verificato
TIM+ non pesato	perde col grado da $k = 20$ in su, $p \leq 0{,}001$
GNN sugli archi, per i seed	stima p l'86% meglio, ma nessun vantaggio coerente sui seed: tre budget, tre risposte
loss pesata sugli hub	respinta su **entrambi** i substrati, $-2{,}1\%$ e $-2{,}0\%$
R-SIGN	la struttura relazionale informa gli alberi ($p = 0{,}006$), non la GNN ($p = 0{,}22$)
fusione convenzionale	$-0{,}15$ di Q_{tras}, $p < 0{,}001$: il multistrato paga solo tarato
escludere i già attivi	da -59% a -81%: toglie esattamente chi conta
potere esplicativo assoluto	678 adozioni su 269.081, lo 0,3%: lo shock è esogeno, il modello lo misura ($\times 4{,}55$) ma non lo contiene

Le due tesi

Il substrato decide, e si può sapere prima

Prima di costruire qualunque cosa basta una misura semplice — i vicini contano davvero, o è solo il grado? — e la risposta dice già se il resto del lavoro troverà qualcosa.

StackExchange: -0%, ogni componente nulla. Higgs: $+73\%$, le stesse componenti danno segnale.

Una pipeline con risultati positivi su entrambi sarebbe *meno* credibile.

Prevedere prima di ottimizzare

Chi massimizza *quanti* nodi perde contro il grado. Chi sa *chi* adotterà — anche solo un po', AUC 0,68 — lo batte.

Sapere *come* si trasmette (p sugli archi) non ha pagato sui seed; sapere *a chi* ($\hat{p}$ sui nodi) sì.

Le comunità sono il pezzo di conoscenza che pesa di più.

Quello che ci portiamo via è soprattutto un modo di lavorare: decidere il criterio prima di vedere i dati, giudicare sulle adozioni vere e non sulle simulazioni, mettere accanto a ogni numero quanto rumore c'è, e raccontare anche ciò che non ha funzionato.

Grazie per l'attenzione

Davide Cinelli · Giuseppe Cuiuri